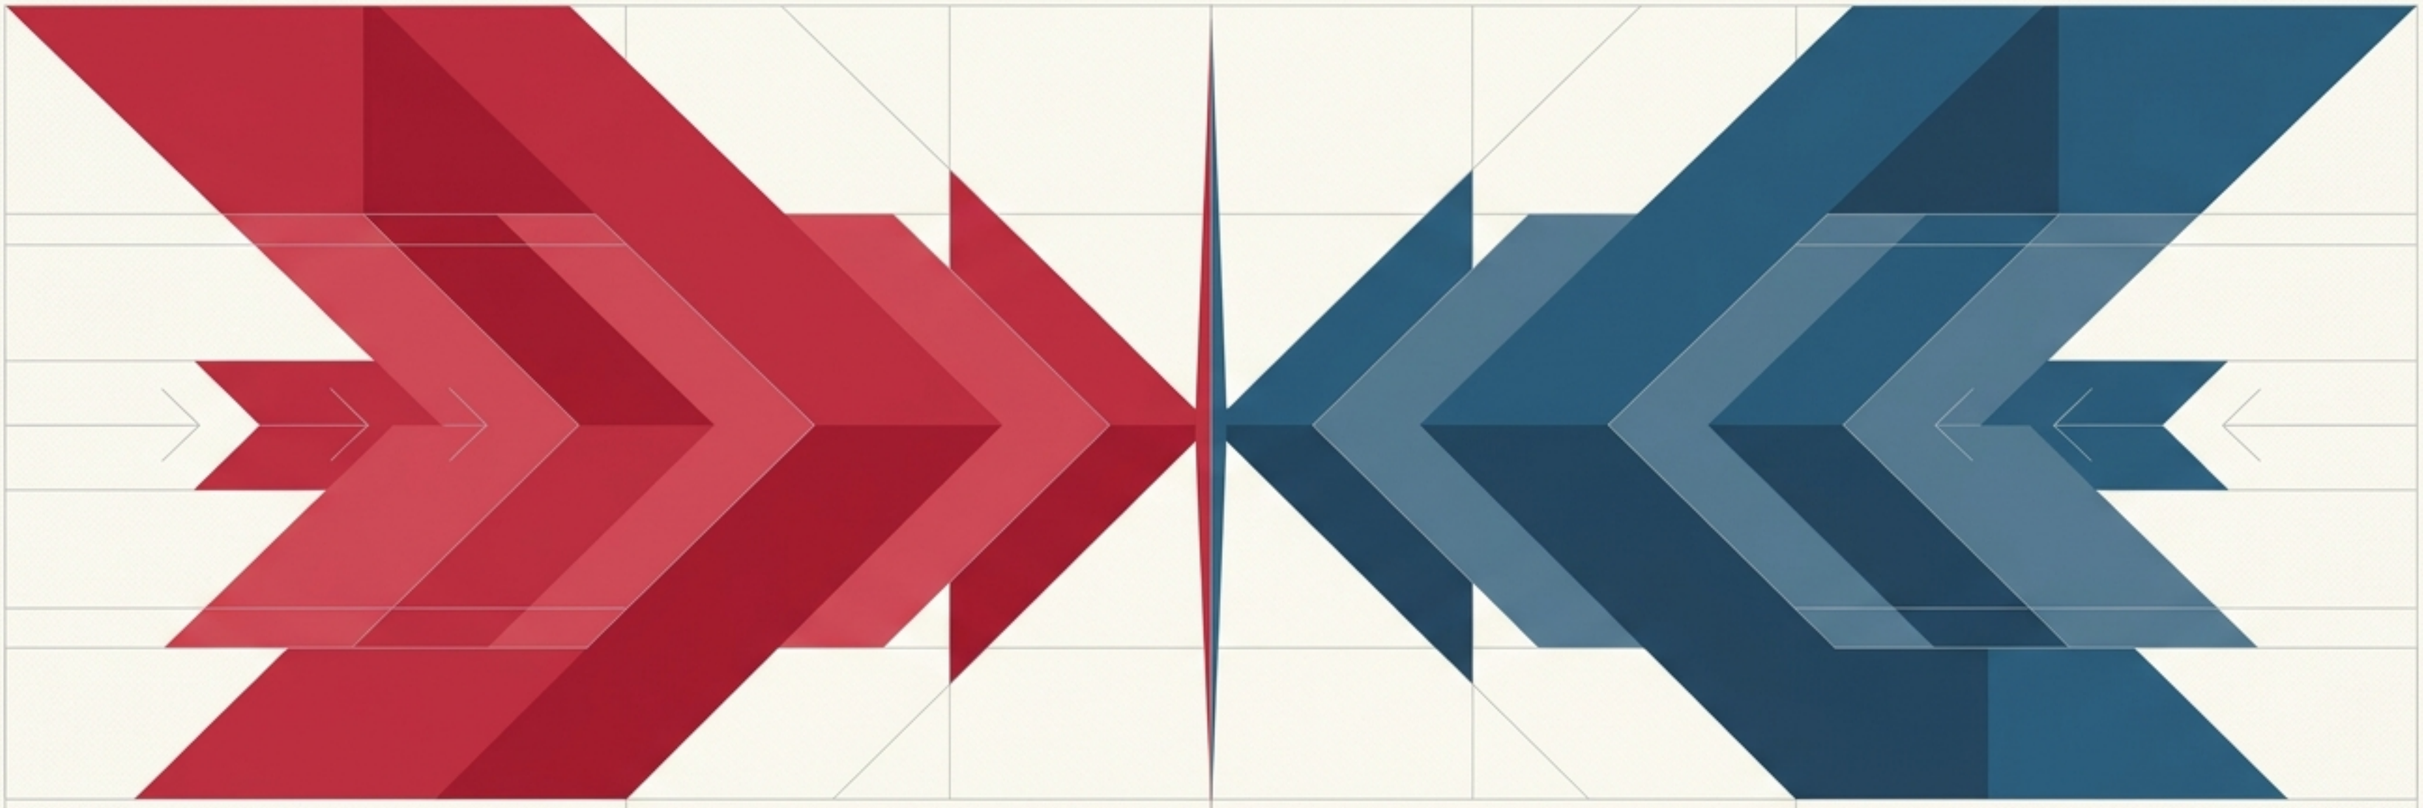


MAKİNE ÖĞRENİMİ MODELLERİNİ YORUMLAMAK

SHAP: BİR AÇIKLAMANIN ANATOMİSİ

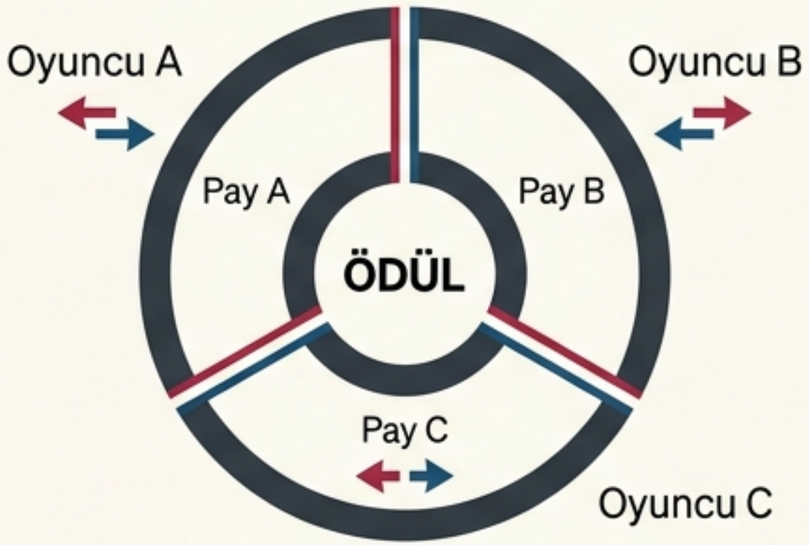
Oyun Teorisinden Topluluk Ağaçlarına, Kara Kutu Modellerini Aydınlatan Matematiksel Çerçeve

Gemini Notebook

Lloyd Shapley'den Lundberg ve Lee'ye (2017)

Oyun Teorisi (1953)

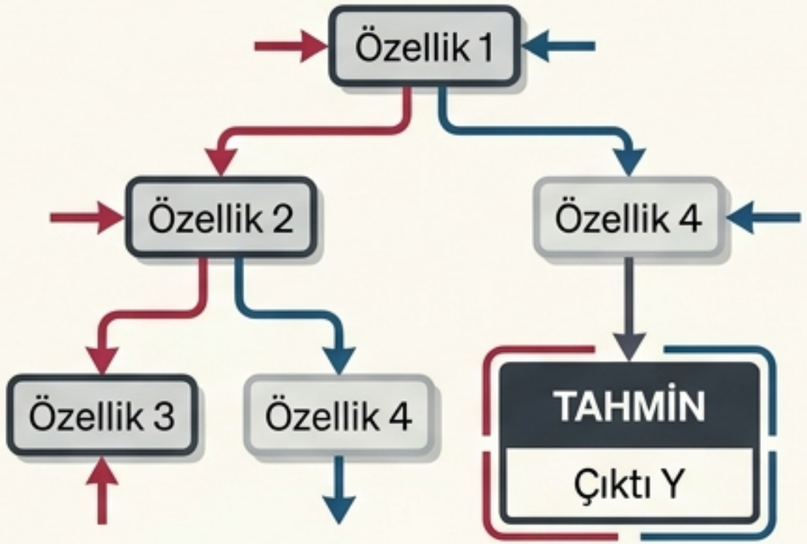
'Shapley Değerleri (Lloyd Shapley)'



Soru: Bir 'ödül' (payout), koalisyondaki oyuncular arasında adil bir şekilde nasıl dağıtılır?

Makine Öğrenimi (2017)

'SHAP (Lundberg & Lee)'



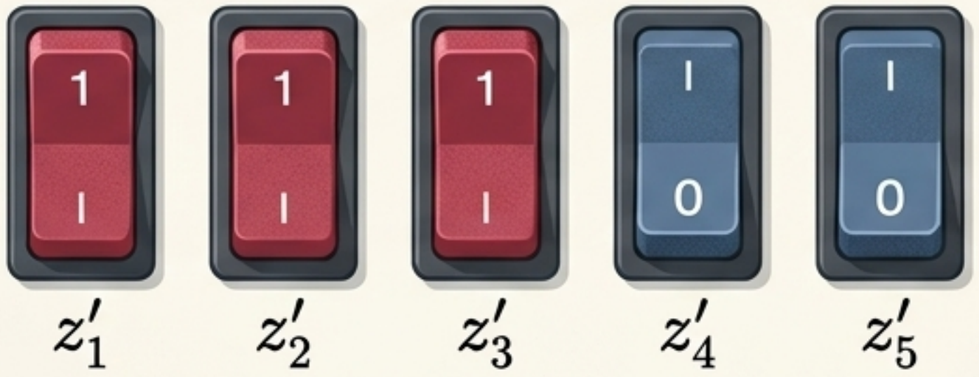
Soru: Bir 'tahmin' (prediction), veri özellikleri arasında nasıl paylaştırılır?

Sonuç:

SHAP yalnızca Shapley değerlerinin yeniden markalaşması değildir; hesaplamayı hızlandıran ve yöntemi metin/görüntü modellerine genişleten 'Shapley 2.0' vizyonudur.

Gemini Notebook

Açıklama Modeli: Koalisyon Vektörü



[1] Sahada / Mevcut
(Orijinal değer)

[0] Yedek Kulübesinde / Yok
(Rastgele arka plan değeri)

g : Açıklama Modeli

z' : Koalisyon Vektörü
(Basitleştirilmiş özellikler)

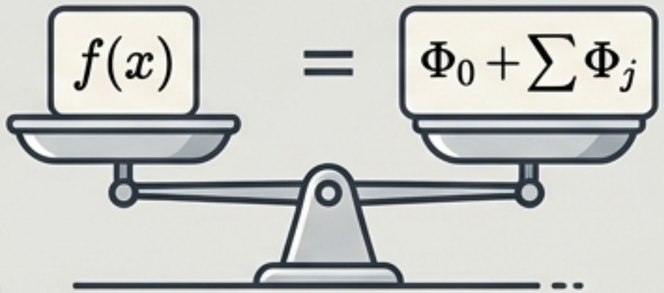
Φ_j : Shapley Değeri
(Özellik j'nin katkısı)

$$g(z') = \Phi_0 + \sum_j \Phi_j z'_j$$

Temel Kavram: Özellik değerleri 'oyuncular'dır. SHAP, bazı özelliklerin oyunda olduğu (1) ve bazılarının rastgele arka plan değerleriyle değiştirildiği (0) binlerce koalisyon simülasyonu üzerinden Shapley değerlerini hesaplar.

Gemini Notebook

Oyun Teorisinin Üç Temel Sütunu



1. Yerel Doğruluk (Local Accuracy)

SHAP değerlerinin toplamı (temel değer Φ_0 ile birlikte), modelin o veri noktası için ürettiği asıl tahminine tam olarak eşittir.



2. Eksiklik (Missingness)

Eksik veya yok sayılan ($x'_j = 0$) bir özelliğin atfı kesinlikle sıfır olmalıdır ($\Phi_j = 0$). Bu, sabit özellikler için küçük bir muhasebe düzeltmesidir.



3. Tutarlılık (Consistency)

Bir model değişir ve bir özelliğin marjinal katkısı artarsa veya aynı kalırsa, o özelliğin SHAP değeri asla azalmaz.

Gemini Notebook

SHAP Tahmin Yöntemleri Matrisi

Yöntem	Hesaplama Hızı	Model Uyumluluğu	Temel Mekanizma
KernelSHAP	Yavaş ($O(TL^2M)$) 	Agnostic (Tüm Modeller)	Ağırlıklı Doğrusal Regresyon
TreeSHAP	Çok Hızlı ($O(TLD^2)$) 	Yalnızca Ağaç Modelleri	Ağaç Yolu Yönlendirmesi
Permütasyon	Hızlı	Agnostic (Tüm Modeller)	İleri/Geri Permütasyon

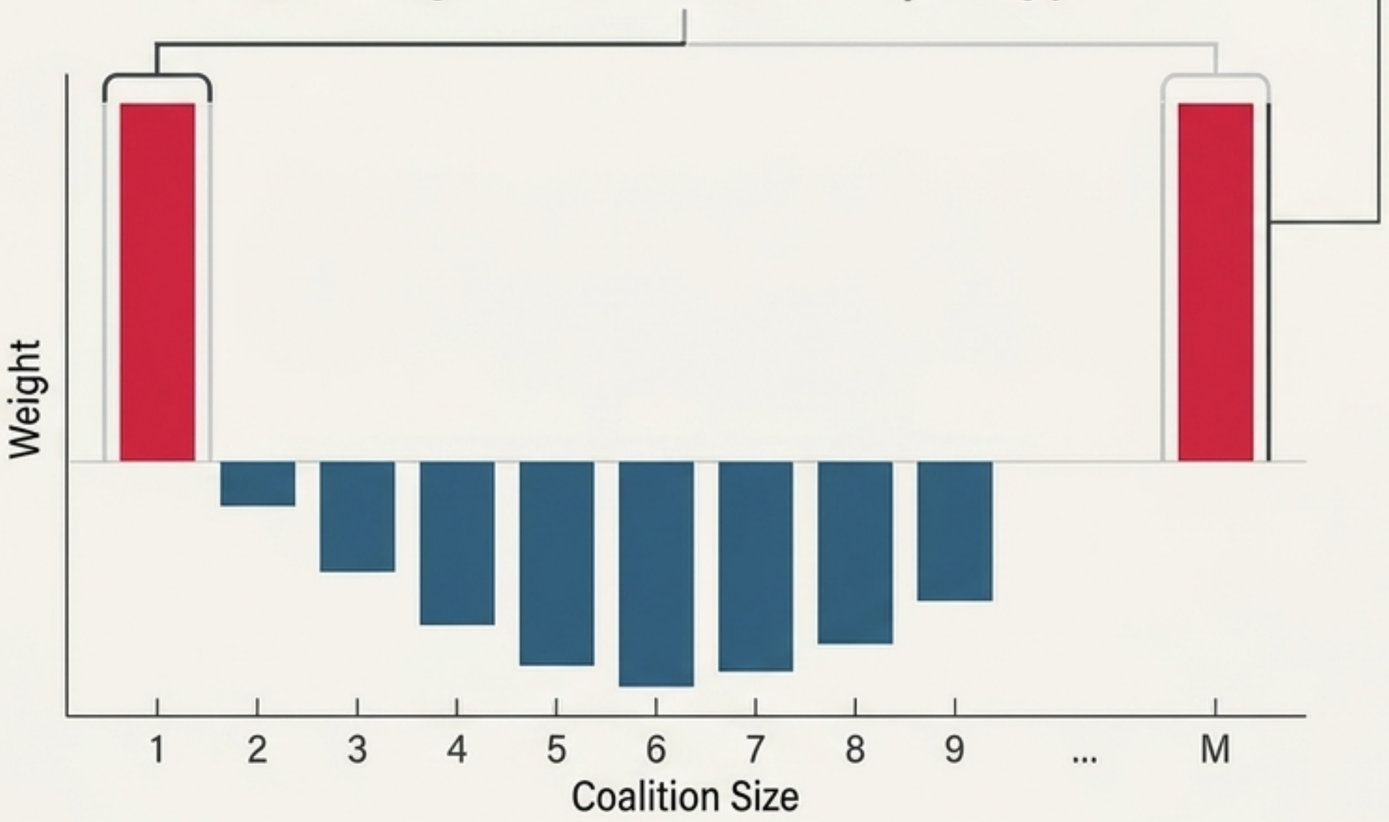
Dikkat! KernelSHAP ve geleneksel tahminler marjinal dağılımları kullanır. Özellikler güçlü bir şekilde bağımlı (korele) ise, gerçekleşmesi zor veri noktalarına ağırlık verebilirler.

Gemini Notebook

KernelSHAP: LIME ile Shapley'nin Birleşimi

Kavram: LIME, örneğe ne kadar yakın olduğuna göre ağırlık verir. SHAP ise izole etkileri öğrenebilmek için koalisyon boyutuna göre ağırlıklandırır.

Tek bir özelliği yalıtmak (1) veya sadece bir özelliği dışarıda bırakmak (M-1), o özelliğin saf etkisi hakkında en çok bilgiyi verir.



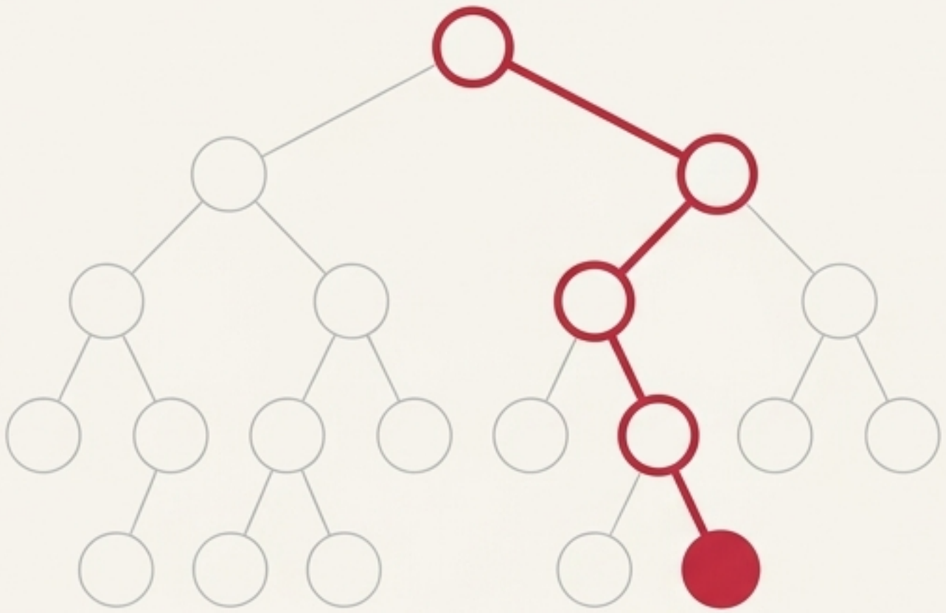
1. Koalisyonları örnekle.
2. Orijinal özelliklere dönüştür.
3. SHAP Kernel ile ağırlıkları hesapla.
4. Ağırlıklı doğrusal model eğit.
5. Katsayıları SHAP değerleri olarak döndür.

Gemini Notebook

Optimizasyon: TreeSHAP ve Permütasyon Yöntemi

TreeSHAP

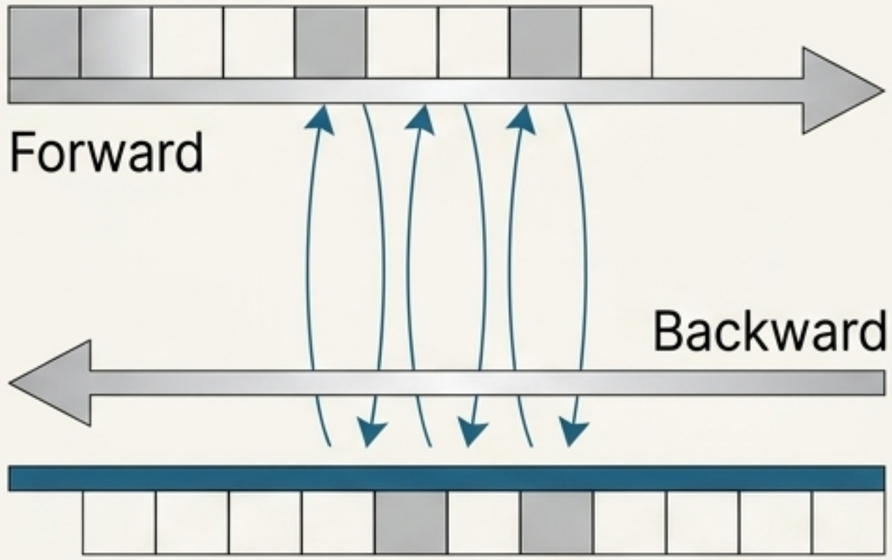
$O(TLD^2)$



Tüm koalisyon kombinasyonları yerine, karar ağacının yapısıındaki sınırlı olası tahmin yollarını izler. Sadece tahmini değiştiren koalisyonları hesaplar.

Permütasyon Yöntemi

Antithetic Sampling



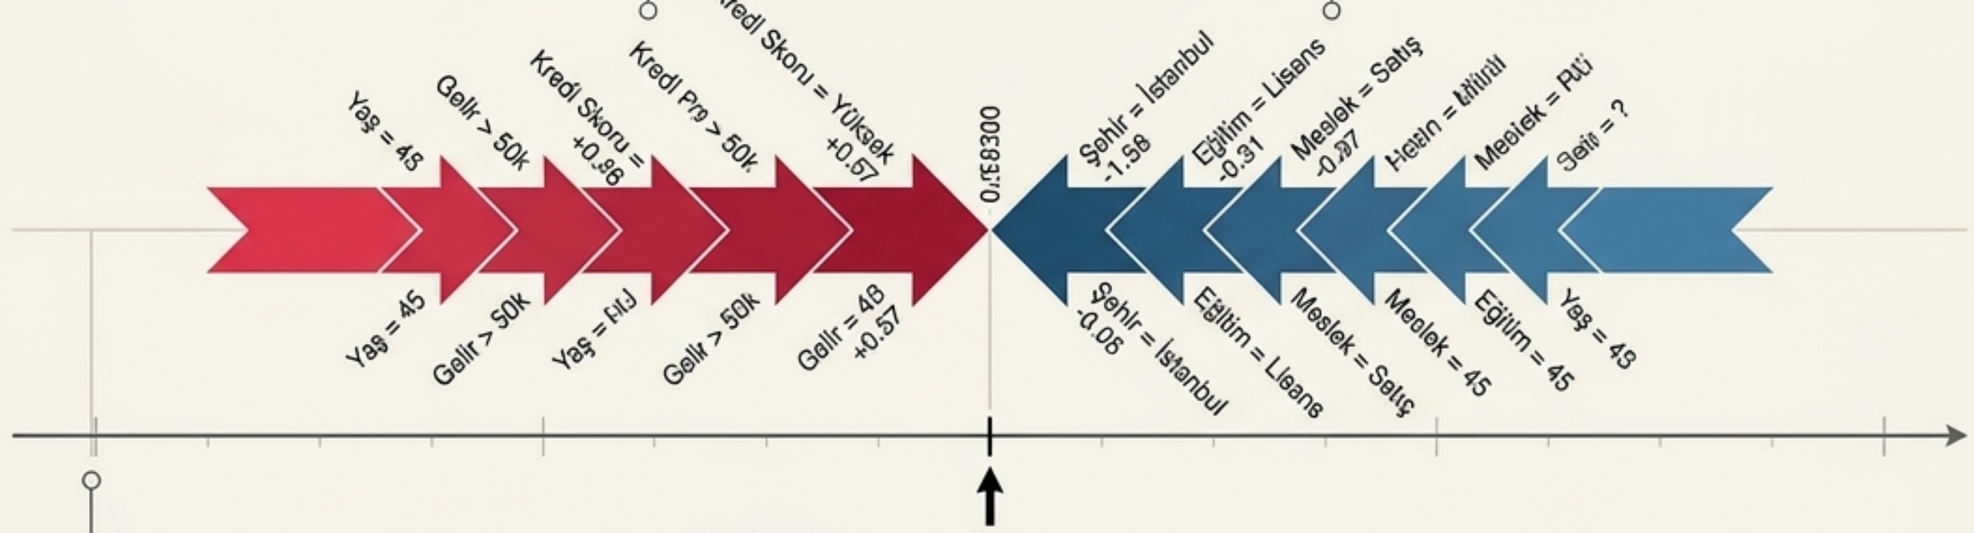
Özellikleri sırayla (ileri ve geri) ekleyerek marjinal katkıları hesaplar. Her permütasyon bir özellik değiştirir, gereken model çağrısı sayısı büyük ölçüde azalır.

Gemini Notebook

Yerel Açıklamalar: Kuvvet Grafiği (Force Plot) Anatomisi

Pozitif Kuvvetler:
Tahmini temel değerin üzerine iten özellikler.

Negatif Kuvvetler:
Tahmini aşağıya, negatif yöne çeken özellikler.



Temel Değer (Base Value):
Modelin tüm veriler üzerindeki ortalama tahmini. Referans noktasıdır.

Çıktı (Model Output)

Çıktı (Model Output):
Kuvvetlerin dengelendiği nihai nokta. Gerçek tahmin değeri.

Gemini Notebook

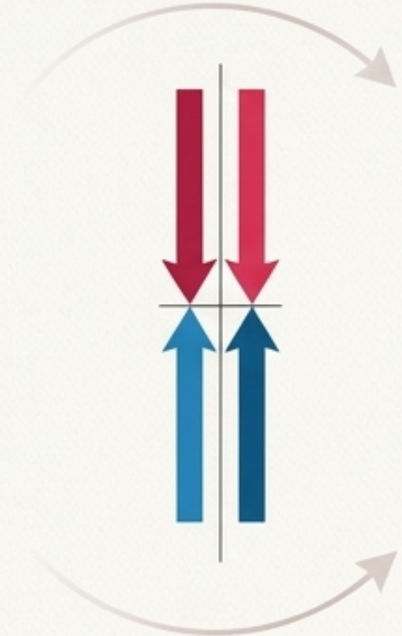
Sentez: Mikrodan Makroya Geçiş

Küresel davranış, yerel gerçeklerin birikimidir.

1. Tekil Açıklama



2. Dikey Döndürme



3. Küresel Topografya

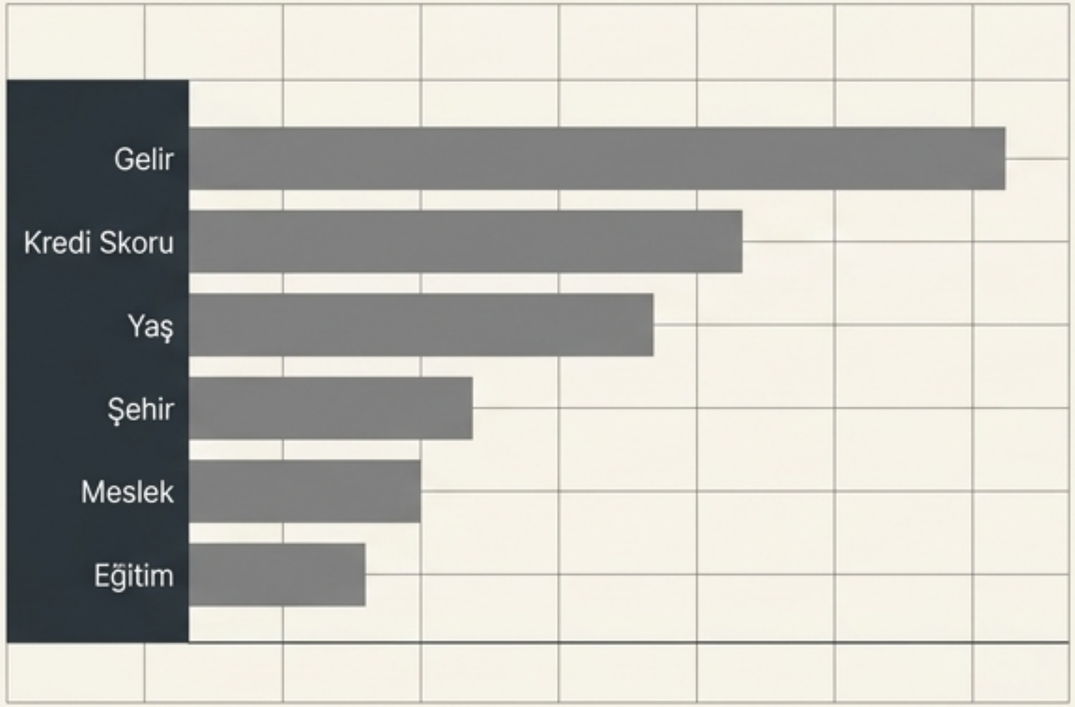


SHAP'ın en büyük yeniliği, global açıklamalar (summary) ile lokal açıklamaların (Shapley değerleri) **mükemmel şekilde tutarlı olmasıdır.** **Yığılmış** kuvvet grafikleri kümelenerek, tekil örneklerin ötesinde tüm veri setinin model tarafından nasıl algılandığına dair bir topografya oluşturur.

Gemini Notebook

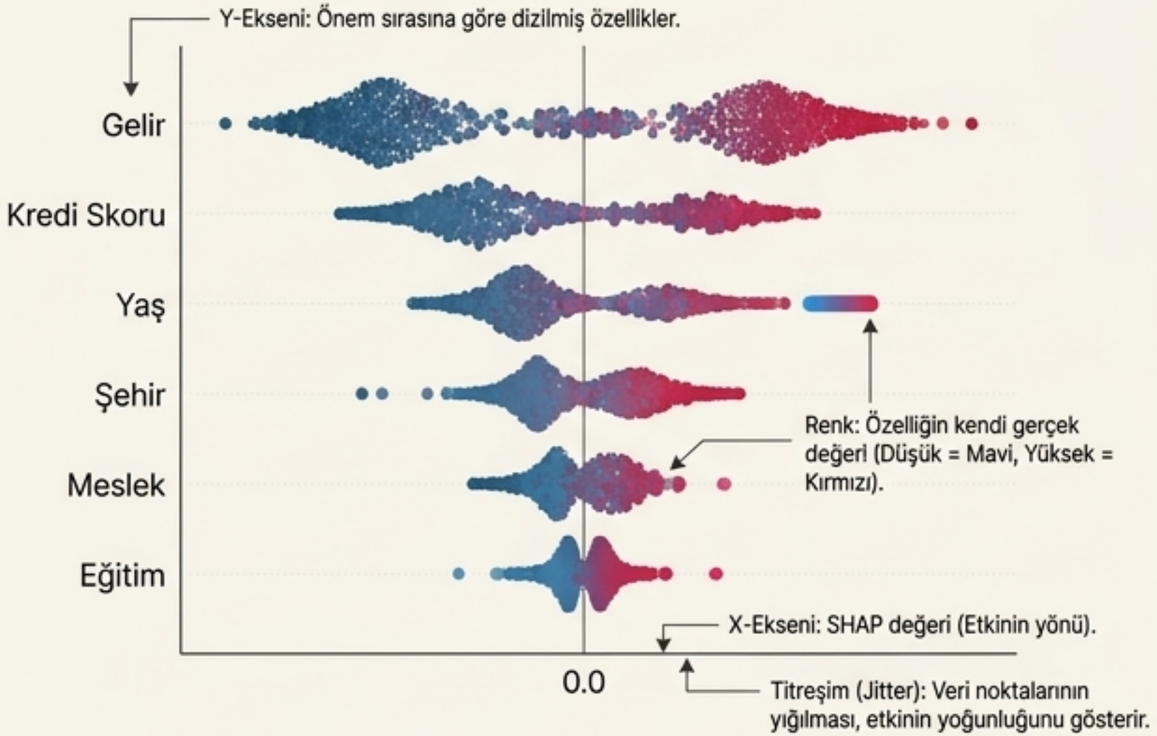
Küresel Etki: Önem ve Özet Grafikleri

SHAP Özellik Önemi



Mutlak Shapley değerlerinin ortalaması. Klasik yöntemler model performansındaki düşüşü ölçerken, SHAP özellik atfının büyüklüğünü ölçer.

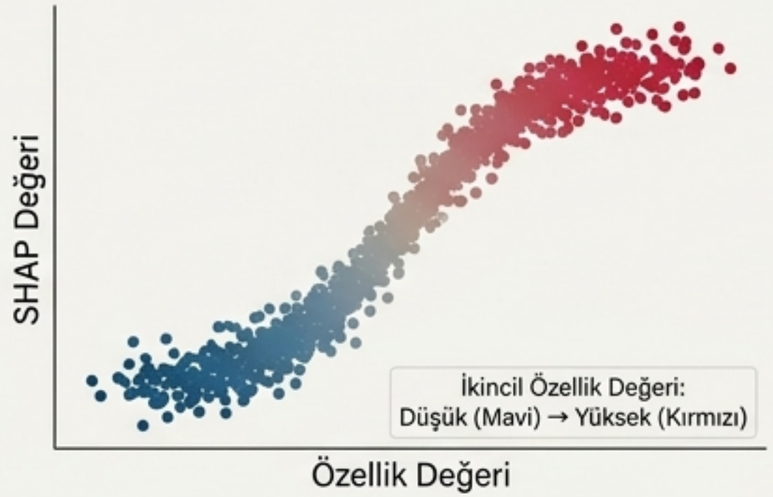
SHAP Özet Grafiği (Summary Plot)



- Y-Ekseni: Önem sırasına göre dizilmiş özellikler.
- X-Ekseni: SHAP değeri (Etkinin yönü).
- Renk: Özelliğin kendi gerçek değeri (Düşük = Mavi, Yüksek = Kırmızı).
- Titreşim (Jitter): Veri noktalarının yığılması, etkinin yoğunluğunu gösterir.

Gemini Notebook

Derinlemesine Etki: Bağımlılık ve Etkileşim



Bağımlılık Grafiği (Dependence Plot):

X-ekseni özellik değeri, Y-ekseni SHAP değeri. PDP/ALE'den farklı olarak, dikey dağılım (varyans) direkt olarak etkileşimleri gösterir.

Etkileşimin Anatomisi

$$\boxed{\text{Toplam Etki}} = \boxed{\text{Ana Etki } (A)} + \boxed{\text{Ana Etki } (B)} + \boxed{\text{Saf Etkileşim } (A \times B)}$$

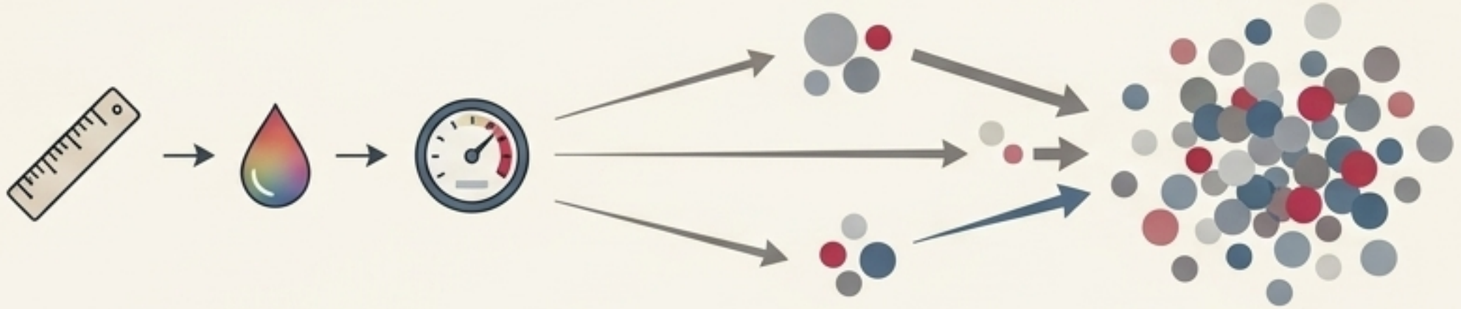
Shapley etkileşim indeksi, özelliklerin bireysel ana etkilerini çıkararak, yalnızca özelliklerin birlikte var olmasından kaynaklanan saf etkileşimi izole eder.

Gemini Notebook

SHAP Değerleri ile Kümeleme (Clustering)

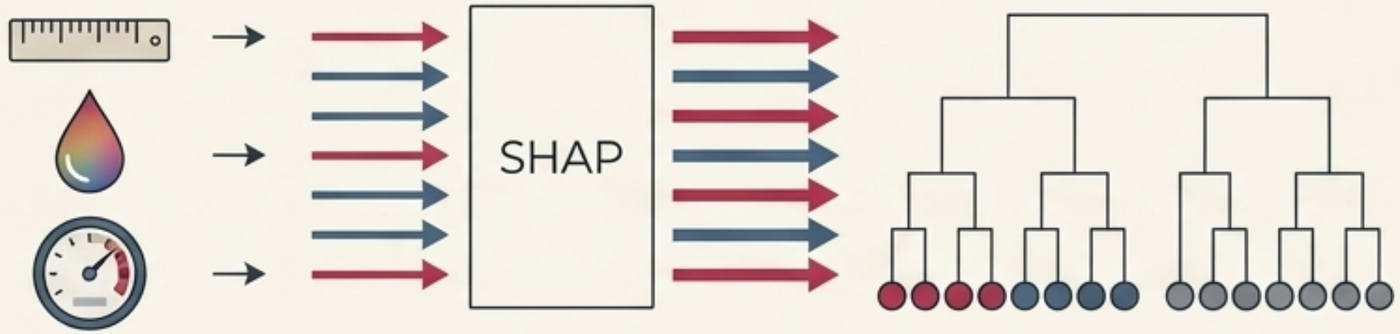
Geleneksel Kümelemenin Zorluğu

Boy, kilo, renk gibi farklı birimlerdeki veriler arasında mesafe ölçmek yanıltıcı olabilir.



Açıklama Benzerliği (Explanation Similarity)

Tüm SHAP değerleri aynı birimdedir (Tahmin uzayı).
Sonuç: Özellik değerleri çok farklı olsa bile, model tarafından aynı sebeple aynı tahmine itilen örnekleri keşfetmenizi sağlar.



Gemini Notebook

Pragmatik Sentez: SHAP'ın Güçlü ve Sınırlı Yönleri

İtici Kuvvetler (Güçlü Yönler)

- **Teorik Temel:** Oyun teorisinin adil dağıtım aksiyomlarıyla desteklenir.
- **Zıtlık:** Tahmini, ortalama (temel) tahminle karşılaştırır.
- **Birleştirici:** Makine öğrenimi yorumlanabilirliğini tek çatı altında toplar.
- **Küresel-Yerel Tutarlılığı:** Küresel grafikler, atomik yerel hesaplamalara dayanır.

Çekici Kuvvetler (Sınırlandırmalar)

- **Hesaplama Maliyeti:** TreeSHAP dışında hala oldukça yavaştır.
- **Bağımlılık İhlali:** KernelSHAP, özellikler korele olduğunda imkansız veriler üretebilir.
- **Yanıltıcı Yorumlar:** Adversarial saldırılara açıktır; yanlılıklar (bias) kasıtlı gizlenebilir.

Gemini Notebook

Yazılım Ekosistemi ve Araçlar



Sonuç: Modern ekosistem bu teorik gücü birkaç satır koda indirgemiştir. Ancak güvenli kullanım, arka plandaki marjinal varsayımları bilmekten geçer.

Gemini Notebook